

교수님 검토용 설명 자료

항목	내용
논문	저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지
저자	이정빈, 김은경* (국립한밭대학교)
투고처	2026 KICS 추계종합학술발표회 학부논문 (A4 2 쪽, 마감 10 월 2 일 24:00)
원고	GitHub leejb020313/KICS_paper_2609, release 브랜치, paper/cascade_kics_draft.pdf
작성일	2026-10-01

1. 한 장 요약

무엇을 했다. 팩트체크가 필요한 문장을 골라내는 작업에서, 가벼운 분류기(임베딩 SVM)가 모든 문장을 먼저 판정하고 **확신하지 못하는 절반에만** 대형 언어 모델(LLM)을 호출합니다. 호출한 문장은 LLM 의 답으로 바꾸지 않고, **두 모델의 점수를 결합**해 최종 판정합니다.

핵심 결과 (Claude Sonnet 5, 테스트 정확도, 5 회 반복 평균)

	LLM 을 모든 문장에 호출	제안 방법 (절반만 호출)
정확도 (CLEF / ClaimBuster)	0.915 / 0.835	0.923 / 0.846
LLM 비용 (1,000 문장당)	\$0.168	\$0.084 (−50%)
처리 시간 (1,000 문장당)	107 초	60 초 (−44%)

한 줄 메시지. LLM 호출을 절반으로 줄여도 정확도는 떨어지지 않습니다. 5 회 반복 모두에서 “0.6%p 넘게 낮지 않다”를 통계적으로 확인했습니다. 같은 조건에서 LLM 답으로 교체하는 기존 방식은 ClaimBuster 에서 이를 보장하지 못했습니다.

교수님께 여쭙볼 것 (자세한 내용은 6 절)

- ClaimBuster 의 양성 F1 에서는 LLM 전량 호출이 더 높습니다. 원고에 밝힐까요?
- “결합 가중치를 학습하지 않으면 정확도가 떨어진다”는 추가 결과를 원고에 넣을까요?
- JEV 를 첫 단계로 쓴 별도 원고를 따로 투고해도 될까요?

2. 지난 검토(9 월 29 일) 이후 바뀐 점

- **핵심 주장의 근거를 바꿨습니다.** 전에는 “전량 호출과 유의한 차이가 없다”였는데, 이는 차이를 못 찾았다는 뜻일 뿐이라 약했습니다. 지금은 차이의 95% 신뢰구간으로 “0.6%p 넘게 낮지 않다”를 직접 보입니다 (3 절).
- **비용과 시간을 실제로 측정했습니다.** 전에는 호출률만 보고했습니다.
- **두 번째 LLM(Claude Haiku 4.5)으로 같은 실험을 반복했습니다.** “LLM 이 하나뿐”이라는 한계를 보완하기 위해서입니다. 결과를 보기 전에 기준을 정해 두었고, 통과하지 못한 기준도 원고에 적었습니다.
- **최신 관련 연구(SRR)와의 차이를 2.1 절에 넣었습니다.**
- **요약과 서론을 처음 보는 사람도 이해할 수 있도록 다시 썼습니다.**
- 이메일, 영문 이름(Jeongbin Lee, Eunkyung Kim)을 넣었습니다.

3. 핵심 주장과 근거

주장. 제안 방법은 LLM 호출을 절반으로 줄여도 전량 호출과 같은 수준의 정확도를 유지합니다.

근거. 제안 방법과 전량 호출의 정확도 차이에 대해, 테스트 문장을 2,000 번 다시 뽑는 부트스트랩으로 95% 신뢰구간을 구했습니다. 아래 표는 5 회 반복 중 **가장 나빴던 회차의 신뢰구간 하한**입니다. 이 값이 -0.6%p 보다 위에 있다는 것은 “제안 방법이 전량 호출보다 0.6%p 넘게 나쁘지 않다”는 뜻입니다.

호출률 50%	CLEF	ClaimBuster
제안 방법 (결합)	-0.35%p	-0.58%p
기존 방법 (교체)	-0.59%p	-2.26%p

- 제안 방법은 두 데이터셋 모두에서 기준을 만족합니다. 평균으로는 오히려 0.8%p, 1.1%p 높습니다.
- 기존 방법(교체)은 ClaimBuster 에서 하한이 -2.3%p 까지 내려가 이를 보장하지 못합니다. 따라서 이 보장은 “절반만 호출하는 구조”가 아니라 “**결합**” 덕분입니다.
- 두 번째 LLM(Haiku 4.5)에서도 구도가 같습니다. 제안 방법의 하한은 -1.6%p 이상이었고, 교체 방식은 CLEF 에서 -3.1%p 까지 내려갔습니다.

주의. 0.6%p 는 미리 정한 기준이 아니라, 관측된 가장 나쁜 하한(-0.58%p)을 올림한 값입니다. 그래서 원고에는 “δ 안에서 비열등하다”가 아니라 “0.6%p 넘게 낮지 않음을 확인했다”는 사실로만 적었습니다.

4. 설계 선택: 왜 이렇게 했는가

4.1 왜 LLM 을 전부 쓰지 않고 캐스케이드인가

- 실제 팩트체크 서비스 운영사가 “모든 문장에 대형 LLM 을 쓰는 것은 운영 규모에서 감당하기 어렵다”고 보고했습니다 [1].
- 같은 연구진이 “가벼운 모델이 확신하지 못할 때만 LLM 에 넘기는 방식”을 향후 과제로 제시했습니다 [2].
- 이 논문은 그 과제를 구현하고 평가한 것입니다.

4.2 왜 첫 단계가 임베딩 SVM 인가

결론: 더 정확한 대안은 있지만, 비용과 시간을 줄이는 이 논문의 목적에는 지금 선택이 맞습니다.

첫 단계 분류기	제안 방법(50%) 정확도	문장당 CPU 시간
임베딩 SVM (논문)	0.920 / 0.847	6.6 ms
같은 임베딩 + 로지스틱 회귀	0.919 / 0.848	비슷
임베딩 SVM, 하이퍼파라미터 튜닝	0.921 / 0.845	비슷
더 큰 임베딩(mpnet) + SVM	0.925 / 0.856	43 ms

※ 이 표는 별도 비교 실험의 결과라, 표본 추출 방식 차이로 논문 수치(0.923 / 0.846)와 조금 다릅니다. 모든 행을 같은 방식으로 비교했습니다.

- 더 큰 임베딩은 0.5~0.9%p 더 정확하지만 첫 단계가 6.5 배 느려집니다. 그러면 시간 절감이 44%에서 약 10%로 줄어듭니다(추정).
- 지금 임베딩은 비교 대상인 NN-PPI 가 쓰는 것과 **같은 것**입니다. 그래서 “같은 정보로 NN-PPI 보다 같거나 낫다”는 비교가 공정합니다 (SVM 0.859 / 0.790 대 NN-PPI 0.834 / 0.785).
- 파인튜닝한 인코더(RoBERTa 등)는 GPU 가 필요해 시험하지 않았습니다.

4.3 왜 LLM 답으로 교체하지 않고 결합하는가

결론: LLM 이 “사실 확인이 필요하다”고 보는 기준이 데이터셋의 정답 기준과 달라서입니다.

- LLM 점수를 그대로 쓰면 정밀도는 0.98 / 0.91 로 높지만 재현율은 0.61 / 0.42 에 그칩니다. LLM 이 정답보다 훨씬 보수적으로 판정한다는 뜻입니다.
- 결합 공식은 분류기가 “불필요” 쪽으로 강하게 기울수록 LLM 에 더 높은 기준을 요구합니다. 교체 방식은 항상 같은 기준을 씁니다.
- **실제 사례:** 한 계약 문장(정답: 불필요)의 LLM 점수는 0.35 였습니다. 고정 기준 0.16 을 쓰는 교체 방식은 “필요”로 틀렸지만, 제안 방법은 분류기 판단 때문에 기준이 0.41 로 올라가 맞았습니다.
- 같은 문장을 호출할 때 결합 방식은 모든 호출률에서 교체 방식보다 평균 정확도가 높았습니다.

4.4 왜 이 결합 공식(로지스틱 회귀)인가

결론: 시험한 대안 중 가장 좋거나 공동 1 위이고, “가중치를 학습한다”는 점이 핵심입니다.

결합 방식	제안 방법(50%) 정확도
로지스틱 회귀 (논문 식 1)	0.920 / 0.847
상호작용항 추가	0.920 / 0.848
LLM 점수에 로그 변환	0.917 / 0.840
그래디언트 부스팅	0.916 / 0.843
학습 없이 단순 평균	0.915 / 0.836

- 더 복잡한 모델은 나아지지 않았습니다. 학습 데이터가 1~2 천 문장이라 계수 3 개짜리 모델이 안정적입니다.
- **학습 없이 평균하면 확실히 떨어집니다** ($-0.5 / -1.1\%$ p). 라벨로 결합 가중치를 학습해야 LLM 과 정답 기준의 차이를 보정할 수 있다는 직접 근거이며, 최신 관련 연구 [8]과 구별되는 지점입니다.
- 결합 모델을 “실제로 호출되는 절반”으로만 학습해 봐도 나아지지 않았습니다 (0.9195 / 0.8463).

4.5 왜 호출률 50%인가

- 테스트를 보지 않고 학습 데이터만으로 정했습니다. 50% 이후로는 더 호출해도 정확도가 CLEF 0.06%p, ClaimBuster 0.11%p 만 올랐습니다.
- 평균 정확도만 보면 제안 방법은 CLEF 30%, ClaimBuster 40%에서 이미 전량 호출 수준에 도달합니다. 다만 30~40%에서는 3 절의 “0.6%p 보장”이 성립하지 않아, 원고에는 “평균 도달”로만 적었습니다.
- **주의:** “증가 0.1%p 이하”를 엄격한 규칙으로 쓰면 ClaimBuster 는 60%가 됩니다. 그래서 원고에는 규칙처럼 쓰지 않고 실제 증가값을 그대로 적었습니다.

4.6 LLM, 데이터, 비교군 선택

선택	이유
LLM: Claude Sonnet 5	선행 연구의 가장 강한 설정이 “상용 LLM + NN-PPI”라 같은 급으로 비교. 2 차 확인은 Haiku 4.5
40 문장씩 묶어 LLM 채점	호출 수 절감. 1 문장씩 채점한 결과와 품질 차이 없음 (AUC 0.991 대 0.990)
프롬프트: NN-PPI 의 판정 기준	비교 대상과 같은 기준이어야 차이가 방법에서 나온다고 말할 수 있음
데이터: CLEF 2024, ClaimBuster	NN-PPI 가 쓴 데이터라 원 논문 수치와 직접 비교 가능
NN-PPI 재현 (Gemma 3 4B)	원 논문 설정 그대로. 가중 F1 0.835 / 0.785 (원 논문 0.827 / 0.760)

선택	이유
비교군: 교체 방식 (같은 호출률)	같은 문장을 호출하므로 차이가 "판정 방식"에서만 생김
비교군: 전량 호출은 두 설정 중 강한 쪽	약한 쪽과 비교해 유리하게 보이지 않도록

4.7 평가 방법

선택	이유
지표: 정확도	문장별로 맞춤/틀림이 정해져 짝지은 검정이 가능. 가중 F1 로 바뀌도 제안 방법이 가장 높음
학습 데이터 80%로 5 회 반복	특정 학습 데이터에 유연히 맞춘 결과가 아님을 확인
회차별 McNemar 검정, 유의한 횟수 보고	같은 문장에 대한 두 방법 비교의 표준 검정
다중 비교 보정 없음 (원고에 명시)	NLP 분야 관례. 핵심 주장은 신뢰구간 기반이라 보정과 무관
비용: 실측 토큰 × 정가	테스트 배치 23 개를 다시 호출해 측정. 도구가 덧붙이는 프롬프트는 제외

5. 약점과 대응

약점	현재 대응	질문을 받으면
영어 데이터셋 2 개, 출처가 겹침	결론에 한계로 명시	세 번째 데이터(COVID 트윗)도 시험했으나 미리 정한 기준을 모두 통과하지는 못해 범위를 두 데이터셋으로 유지했다
ClaimBuster 양성 F1 은 전량 호출이 더 높음 (0.729 대 0.716)	원고 미기재 (6 절 질문 1)	원고 지표는 정확도이고 가중 F1 로는 제안 방법이 가장 높다. 데이터가 불균형(필요 문장 27%)이라 지표에 따라 달라진다
Haiku 에서는 "NN-PPI 적용 전량 호출보다 높음"이 성립하지 않음	원고에 명시	핵심 주장(전량 호출과 같은 수준)은 Haiku 에서도 성립한다. 다만 보장 폭은 1.6%p 로 Sonnet 5(0.6%p)보다 넓다
결합 > 교체의 유의성은 일부 호출률에서만	평균 우위만 서술	핵심 근거는 3 절의 신뢰구간 비교다

약점	현재 대응	질문을 받으면
다중 비교 보정 없음	원고에 명시	부가 비교만 해당하고, 핵심 주장은 신뢰구간 기반이다
비용은 표본 재측정	원고에 "배치 23 개 재호출" 명시	병렬 호출·할인을 쓰면 금액은 달라지지만, 호출 수에 비례한다는 점은 같다
넘길 문장을 학습으로 고르는 방법(SRR)과 미비교	2.1 절에 차이 서술	SRR 은 넘길 문장을 교체한다. 우리 결합 방식과 함께 쓸 수 있다

6. 결정이 필요한 것

- 1. ClaimBuster 양성 F1 결과를 원고에 밝힐지** - 공식 지표(양성 F1)로 보면 ClaimBuster 에서는 전량 호출(임계값 조정)이 0.729 로, 제안 방법 0.716 보다 높습니다. CLEF 에서는 제안 방법이 0.861 로 가장 높습니다.
- 넣으면 원고에서 한 줄이 늘어나 다른 문장을 줄여야 합니다.
- 2. "학습 없이 평균하면 떨어진다" 결과를 원고에 넣을지** - 결합 가중치를 학습하는 이유의 직접 근거입니다(4.4 절). - 넣으려면 유의성 검정을 추가하고 한 줄을 줄여야 합니다.
- 3. JEV 버전 원고를 따로 투고할지** - 상용 판정 모델 JEV 를 첫 단계로 쓴 원고(jev-paper 브랜치)도 2 쪽으로 완성되어 있습니다. - 데이터와 결합 방법이 겹쳐 중복 투고로 보일 수 있습니다.

부록: 근거 파일 (저장소 기준)

내용	파일
본 결과	results/final_results_full.json, results/seed_robustness_full.json
신뢰구간 (3 절)	scripts/equivalence.py → results/equivalence.json
비용·시간	scripts/cost_time.py → results/cost_time.json
두 번째 LLM	results/haiku_preregistration.md, results/seed_robustness_full_haiku.json
첫 단계·결합 공식 비교 (4.2, 4.4 절)	scripts/ablation_stage_fusion.py, scripts/ablation_fusion_region.py

내용	파일
원고 숫자 자동 검증	scripts/verify_paper_numbers.py
참고문헌 원문 인용 검증	paper/references/references.json, paper/references/verify_references.py