

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈, 노고산, 김은경
국립한밭대학교

20221065@edu.hanbat.ac.kr, {gsnoh, ekim}@hanbat.ac.kr

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee, Gosan Noh, Eunkyung Kim
Hanbat National Univ.

요약

팩트체크 필요성 탐지(check-worthiness detection)는 수많은 문장 중 사실 확인이 필요한 문장을 골라내는 기술이다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 모든 문장에 LLM을 호출하면 비용과 처리 시간이 크게 늘어난다. 본 논문에서는 가벼운 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 확신하지 못하는 문장에만 LLM을 호출하되 분류기의 판정을 LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 두 공개 데이터셋(CLEF 2024, ClaimBuster)에서 평가한 결과, 제안 방법은 LLM 호출을 절반으로 줄이면서도 모든 문장에 LLM을 호출한 경우와 같은 수준의 정확도(CLEF 0.923, ClaimBuster 0.846)를 유지하였다. 정확도는 평균적으로 오히려 0.8~1.1%p 높았고, 5회 반복 모두 차이의 95% 신뢰구간 하한이 -0.6%p 이상이었다. 이를 통해 LLM 비용은 약 50%, 처리 시간은 약 44% 줄일 수 있을 것으로 기대된다.

I. 서론

온라인 허위 정보가 급증하면서 팩트체크의 중요성이 커졌으며, 그 첫 단계는 사실 확인이 필요한 주장을 찾아내는 팩트체크 필요성 탐지이다[3]. 이 단계는 들어오는 모든 문장을 판정해야 하므로 처리할 문장이 매우 많다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 실제 팩트체크 서비스 운영사는 모든 문장에 대형 LLM을 호출하는 것은 운영 규모에서 감당하기 어렵다고 보고하였다[1]. 같은 연구진은 소형 인코더가 확신하지 못하는 문장만 LLM에 넘기는 방식을 향후 과제로 제시하였다[2].

이처럼 가벼운 모델이 먼저 판정하고 확신하지 못하는 입력만 큰 모델에 넘기는 구조를 캐스케이드라 하며, 일반적으로 넘긴 입력의 판정은 큰 모델의 판정으로 교체한다[5]. 그러나 어떤 문장을 사실 확인이 필요하다고 볼지에 대한 LLM의 기준은 데이터셋의 라벨(사람이 붙인 정답)과 다를 수 있으며, 이 경우 교체는 분류기가 이미 맞힌 판정까지 틀리게 바꿀 수 있다[5]. 본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하되, LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 결합 가중치는 라벨로 학습하므로 LLM의 기준과 라벨의 차이를 보정한다.

II. 본론

2.1 선행 연구

NN-PPI[1]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. 넘긴 입력에서만 두 모델의 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었고[6], SRR[5]은 옳은 답을 뒤집는 손실까지 예측하여 넘긴 입력을 고르지만 넘긴 입력은 큰 모델의 답으로 교체한다. 본 논문은 결합 가중치를 라벨로 학습해 LLM의 기준 차이를 반영한다.

2.2 전체 구조

제안 방법(그림 1)에서는 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 가장 불확실한 문장, 즉 결정값의 절댓값 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만

큼 골라 LLM을 호출한다. 호출하지 않은 문장은 분류기의 판정 ($d(x) > 0$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. 결합형 캐스케이드의 전체 구조

2.3 저비용 분류기

문장 x 의 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 라벨이 있는 학습 세트 L (NN-PPI의 보정 세트)을 사용한다. 저비용 분류기(이하 임베딩 SVM)은 NN-PPI가 이웃 검색에 쓰는 문장 임베딩 all-MiniLM-L6-v2를 입력으로 하는 RBF-SVM이다. 클래스 불균형을 고려한 가중치로 L 에서 학습하며, 결정값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이고 절댓값이 클수록 확신이 높다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 분류기의 결정값 $d(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

여기서 (a, b, c) 는 L 에서 5점 교차적합으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 식 (1)을 s 에 대해 정리하면 결합형은 s 를 $(-c - a \cdot d)/b$ 와 비교하므로, 분류기가 '불필요'로 기울수록(d 가 작을수록) LLM에 더 높은 점수를 요구한다. 반면 교체형 캐스케이드(이하 교체형)는 s 를 L 에서 정한 고정 임계값 t 와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 영어 데이터[3]는 2,405문장을 학습 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 사용하였다. 또 다른 데이터셋

인 ClaimBuster[4]는 2012년 토론 1,314문장을 학습 세트로, 2016년 토론 2,745문장을 테스트로 사용하였다. NN-PPI는 원 논문과 같이 Gemma 3 4B로 재현하였으며, 원 논문과 같은 분할에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 0.827, 0.760). LLM은 Claude Sonnet 5를 사용하였고, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다.

3.2 평가 방법

평가 지표는 테스트 정확도이며, 학습 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고한다. 방법 간 차이는 5회 각각의 예측에 McNemar 검정($\alpha=0.05$, 다중 비교 보정 없음)을 적용하고, 차이의 95% 신뢰구간은 테스트 문장 부트스트랩(2,000회)으로 구하였다. LLM 임계값, 결합 계수, 호출률, NN-PPI의 이웃 수 k 는 모두 학습 세트 안에서만 정하였고(두 데이터셋 모두 $k=10$), 임베딩 SVM은 기본 하이퍼파라미터를 사용하였다. 호출률은 학습 세트의 교차검증 정확도가 두 데이터셋 모두 거의 오르지 않는 50%로 정하였다.

3.3 실험 결과

표 1. 테스트 정확도(†: 5회 중 3회 이상 제안보다 유의하게 낮음)

방법	호출률	CLEF	ClaimBuster
Gemma+NN-PPI [1]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.790
LLM 전량 호출	100%	0.896†	0.835
+ 임계값 조정	100%	0.915	0.830†
+ NN-PPI [1]	100%	0.897†	0.826†
교체형 캐스케이드	50%	0.916	0.835†
결합형 캐스케이드 (제안)	50%	0.923	0.846

표 1에서 LLM을 사용하지 않는 임베딩 SVM은 NN-PPI보다 CLEF에서 5회 중 4회 유의하게 높았으며, ClaimBuster에서는 5회 모두 유의차가 없었다.

LLM 점수를 0.5 기준으로 쓰면 재현율이 CLEF 0.61, ClaimBuster 0.42에 그쳤고, 임계값을 조정하면 재현율은 오르나 ClaimBuster 정확도는 0.5%p 낮아졌다. 이는 LLM의 기준이 라벨과 다를 수 있음을 시사한다.

이하 전량 호출은 LLM 전량 호출의 두 설정(조정 전, 임계값 조정) 중 정확도가 높은 쪽(CLEF는 임계값 조정, ClaimBuster는 조정 전)을 뜻한다. 호출률 50%의 결합형은 전량 호출보다 정확도가 평균 0.8%p, 1.1%p 높았고, 5회 모두 차이의 95% 신뢰구간 하한이 $-0.6\%p$ 이상이었다. 반면 같은 호출률의 교체형은 ClaimBuster에서 하한이 $-2.3\%p$ 까지 내려갔다. 또한 결합형은 NN-PPI를 적용한 전량 호출보다 5회 모두 유의하게 높았다($p \leq 0.016$).

테스트 배치 23개를 다시 호출하여 추정한 1,000문장당 LLM 비용(Claude Sonnet 5 정가)은 전량 호출 \$0.168, 결합형 50% \$0.084였고, 순차 처리 시간은 임베딩 SVM을 포함하여 107초, 60초로 추정되었다.

그림 2와 같이 결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았다. 전량 호출의 평균 정확도에 교체형은 호출률 50%에서 이르지만, 결합형은 CLEF 30%, ClaimBuster 40%에서 이르렀다.

두 방법은 같은 문장에 LLM을 호출하므로 차이는 판정 방식에서만 생긴다. 예를 들어 CLEF의 한 공약 문장(라벨: 불필요)은 LLM 점수가 $s=0.35$ 로, 임계값 $t=0.16$ 을 사용하는 교체형은 ‘필요’로 잘못 판정하였으나, 결합형은 분류기의 결정값($d=-0.84$)에 따라 판정 기준이 0.41로 높아져 옳게 판정하였다.

LLM을 Claude Haiku 4.5로 바꾸면 결합형(50%)의 하한은 5회 모두 $-1.6\%p$ 이상이었으나, 교체형은 CLEF에

서 하한이 $-3.1\%p$ 까지 내려갔다. 다만 이때 결합형은 NN-PPI를 적용한 전량 호출(0.930, 0.839)보다 유의하게 높지 않았다.

한편 학습 데이터(2012년 토론)와 시기가 다른 테스트(ClaimBuster 2016년 토론)에서는 분류기의 재현율이 0.59에 그쳐(CLEF 0.85), 결합형도 확인이 필요한 문장을 임계값을 조정한 전량 호출보다 많이 놓쳤다(재현율 0.73 대 0.86). 이때 LLM을 호출한 문장 중 LLM만 ‘필요’로 판정한 비율이 늘어나(학습 데이터 15.9% → 테스트 23.6%, CLEF는 증가 없음) 라벨 없이 노후화의 징후로 쓸 수 있어 보이며, 2016년 토론 중 300문장의 라벨을 학습 세트에 추가하면 나머지 문장에서 재현율이 3.7%p 올랐다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 떠는 표준편차)

IV. 결론

본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하고, 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안하였다. 제안 방법은 LLM 호출을 절반으로 줄이면서도 모든 문장에 LLM을 호출한 경우와 같은 수준의 정확도를 유지하였으며, 이에 따라 LLM 비용은 약 50%, 처리 시간은 약 44% 줄일 수 있을 것으로 기대된다. 다만 학습 시기와 다른 데이터에서는 분류기가 노후화되어 확인이 필요한 문장을 더 놓칠 수 있으며, LLM과 분류기의 판정이 엇갈리는 비율이 그 징후가 될 수 있고 새 데이터 일부로 다시 학습하면 이를 줄일 수 있었다. 또한 CLEF 영어 데이터가 ClaimBuster에서 구축된[3] 두 영어 데이터셋으로만 평가하였으므로, 향후에는 분류기의 주기적 재학습과 다국어 데이터로 평가를 확장할 계획이다.

참고 문헌

- [1] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check—Worthiness Detection," arXiv:2608.30731, 2026.
- [2] P. Amatya and V. Setty, "Multilingual Fact—Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [3] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check—Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [4] F. Arslan et al., "A Benchmark Dataset of Check—Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.
- [5] Z. Wang et al., "Signed Rescue Routing: Harm—Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [6] Y. Zhang et al., "Calibration—Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.