

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈
(소속 입력 필요)
leejb020313@gmail.com

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee
(Affiliation)

요약

팩트체크 필요성 탐지(check-worthiness detection)는 유입되는 문장 중 사실 확인이 필요한 문장을 선별하는 기술로, 모든 문장에 대형 언어 모델(LLM)을 호출하면 비용과 지연이 크다. 본 논문에서는 라벨로 학습한 저비용 분류기가 불확실하게 판정한 문장에만 LLM을 호출하고, LLM의 판정으로 교체하는 대신 두 모델의 점수를 결합하는 결합형 캐스케이드를 제안한다. 또한 선행 연구 NN-PPI를 재현하여, 같은 라벨로 학습한 분류기만으로도 NN-PPI와 같거나 높은 정확도를 얻음을 보인다. CLEF 2024와 ClaimBuster에서 평가한 결과, 제안 방법은 LLM 호출을 절반으로 줄이면서도 LLM만 전량 호출한 경우와 유의한 차이가 없는 정확도(CLEF 0.923, ClaimBuster 0.846)를 달성하였으며, 모든 호출률에서 교체형 캐스케이드보다 높은 평균 정확도를 보였다.

I. 서론

팩트체크 필요성 탐지는 유입되는 모든 문장을 대상으로 사실 확인이 필요한지를 판정하므로 처리할 문장의 수가 많다. 실제 팩트체크 서비스 운영사는 모든 문장에 LLM을 적용하는 것이 비현실적이라고 보고하였으며[1], 같은 연구진은 파인튜닝한 소형 인코더도 LLM과 경쟁할 수 있으나 관용적 표현에서는 LLM이 앞선다고 보고하고, 인코더가 확실하지 못할 때만 LLM에 넘기는 하이브리드 방식을 향후 과제라 제시하였다[2].

이러한 하이브리드는 일반적으로 캐스케이드[4] 형태로 구현되며, 분류기가 넘긴 문장의 판정을 LLM의 답으로 교체한다. 그러나 LLM의 판정 기준이 데이터셋 라벨과 다를 경우, 교체는 분류기의 옳은 판정까지 틀리게 바꿀 수 있다[7]. 본 논문에서는 저비용 분류기가 불확실한 문장에서만 LLM을 호출하고, 두 모델의 점수를 라벨로 학습한 가중치로 결합하는 결합형 캐스케이드를 제안한다. 또한 선행 연구 NN-PPI[1]를 재현하여 저비용 분류기와 비교하고, LLM 단독 판정의 한계를 함께 분석한다.

II. 본론

2.1 선행 연구

NN-PPI[1]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. LabelFusion[3]은 인코더와 LLM의 출력을 결합하지만 모든 입력에 LLM을 호출하며, 넘긴 입력에서만 두 모델의 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었다[8]. 반면 본 논문에서는 팩트체크 필요성 탐지에서 저비용 분류기의 결정값과 LLM 점수를 라벨로 학습한 가중치로 결합하여, LLM과 라벨의 판정 기준 차이를 반영한다.

2.2 전체 구조

그림 1은 제안 방법의 전체 구조를 나타낸다. 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 가장 불확실한 문장, 즉 결정값의 절댓값 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만큼 골라 LLM을 호출한다. 호출하지 않은 문장은

분류기의 판정($d(x)>0$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. 결합형 캐스케이드의 전체 구조

2.3 저비용 분류기

문장 x 의 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 라벨이 있는 학습 세트 L (NN-PPI의 보정 세트)을 사용한다. 저비용 분류기(이하 임베딩 SVM)는 NN-PPI가 이웃 검색에 사용하는 문장 임베딩(all-MiniLM-L6-v2)을 입력으로 하는 RBF-SVM이며, 클래스 불균형을 고려한 가중치로 L 에서 학습한다. 결정값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이며, 절댓값이 클수록 확신이 높다. 추론 시간은 CPU에서 문장당 약 6 ms이다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 분류기의 결정값 $d(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

여기서 (a, b, c) 는 L 에서 5점 교차검정으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 식 (1)을 s 에 대해 정리하면 결합형은 s 를 $(-c-a \cdot d)/b$ 와 비교하게 되므로, LLM 점수의 판정 기준이 분류기의 결정값에 따라 달라진다. 반면 비교 대상인 교체형 캐스케이드(이하 교체형)는 같은 문장에 LLM을 호출하되 d 를 사용하지 않고, s 를 L 에서 정한 고정 임계값 t 와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 영어 데이터[5]는 2,405문장을 학습 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 사용하였다. ClaimBuster[6]는 2012년 토론 1,314문장

과 2016년 토론 2,745문장을 각각 학습 세트와 테스트로 사용하였다. NN-PPI는 원 논문과 같이 Gemma 3 4B로 재현하였으며, 원 논문과 같은 분할(CLEF dev-test, ClaimBuster 2016년)에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 0.827, 0.760). LLM은 Claude Sonnet 5를 사용하였고, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다(문장 단위 채점과 AUC 0.991 대 0.990).

3.2 평가 방법

평가 지표는 테스트 정확도이며, 학습 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고한다. 방법 간 차이는 1회차 예측에 McNemar 검정($\alpha=0.05$)을 적용하여 평가하였다. LLM 임계값, 결합 계수, 호출률, NN-PPI의 이웃 수 k 는 모두 학습 세트 안에서만 정하였고(두 데이터셋 모두 $k=10$), 임베딩 SVM은 기본 하이퍼파라미터를 사용하였다. 호출률은 학습 세트의 교차검증 정확도가 더 오르지 않는 50%로 정하였다(50% 이후 증가 0.1%p 이하, 전량 호출과 0.7%p 이내).

3.3 실험 결과

표 1. 방법별 테스트 정확도 (†: 제안 방법 대비 유의하게 낮음)

방법	호출률	CLEF	ClaimBuster
Gemma 3 4B + NN-PPI [1]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.790
LLM 전량 호출	100%	0.896†	0.835
+ 임계값 조정	100%	0.915	0.830†
+ NN-PPI [1]	100%	0.897†	0.826†
교체형 캐스케이드	50%	0.916	0.835†
결합형 캐스케이드 (제안)	50%	0.923	0.846

표 1은 각 방법의 테스트 정확도를 비교한 결과이다. LLM을 사용하지 않는 임베딩 SVM은 NN-PPI보다 CLEF에서 유의하게 높았고($p=0.013$), ClaimBuster에서는 유의한 차이가 없었다($p=0.79$). 즉 같은 라벨과 임베딩으로 학습한 저비용 분류기만으로도 NN-PPI와 같거나 높은 성능을 얻을 수 있다.

LLM을 모든 문장에 호출하고 점수를 그대로(0.5 기준) 사용하면 정밀도는 CLEF 0.98, ClaimBuster 0.91로 높았으나 재현율은 0.61, 0.42에 그쳤다. 라벨로 임계값을 조정하면 재현율은 0.94, 0.86으로 향상되었으나, ClaimBuster에서는 학습 세트가 클래스 균형인 반면 테스트는 팩트체크가 필요한 문장이 27%여서 정확도가 오히려 0.5%p 낮아졌다. 이는 LLM의 판정 기준이 데이터셋 라벨과 다를 수 있음을 시사한다.

제안한 결합형은 호출률 50%에서 CLEF 0.923, ClaimBuster 0.846의 정확도를 달성하였다. 이는 LLM 전량 호출 중 더 나은 설정(CLEF는 임계값 조정, ClaimBuster는 조정 전)과 유의한 차이가 없는 수준이며($p=0.22, 0.18$), NN-PPI를 적용한 전량 호출보다는 유의하게 높다($p<0.001$). 즉 LLM 호출을 절반으로 줄여도 LLM 전량 호출에 준하는 정확도를 얻는다.

그림 2는 호출률에 따른 테스트 정확도를 나타낸다. 점선은 LLM 전량 호출 중 더 나은 설정이고, 원은 선택한 호출률 50%이다. 결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았으며, ClaimBuster 30~50%와 CLEF 20~30%에서 그 차이가 유의하였다($p\leq 0.023$). 호출률을 100%로 늘리면 정확도가 CLEF 0.1%p, ClaimBuster 0.6%p 더 향상되었고, ClaimBuster에서는 이 차이가 유의하였다($p=0.006$). 또한 테스트 문장을 모아 $|d|$ 순으로 선택하는 대신, 학습 세트에서 정한 $|d|$ 임계값으로 문장마다 호출 여부를 결정해도 정확도는 0.920, 0.845였다(실제 호출률 38%, 49%).

결합형과 교체형은 같은 문장에 LLM을 호출하므로, 두 방법의 차이는 호출 이후의 판정 방식에서 비롯된다. 예를 들어 CLEF의 공약 문장 ‘I’m going to give them \$5,000 to take with them ...’(라벨: 불필요)은 LLM 점수가 $s=0.35$ 로, 임계값 $t=0.16$ 을 사용하는 교체형은 이를 ‘필요’로 잘못 판정하였다. 반면 결합형은 분류기의 결정값($d=-0.84$)에 따라 판정 기준이 0.41로 높아져 옳게 판정하였다. CLEF 1회차에서 LLM을 호출한 절반 중 결합형만 옳게 판정한 문장은 36개, 교체형만 옳게 판정한 문장은 24개였다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 떠는 표준편차)

IV. 결론

본 논문에서는 팩트체크 필요성 탐지의 LLM 호출 비용을 줄이기 위해, 저비용 분류기가 확실한 문장에서만 LLM을 호출하고 두 모델의 점수를 결합하는 결합형 캐스케이드를 제안하였다. 제안 방법은 LLM 호출을 절반으로 줄이면서도 LLM만 전량 호출한 경우와 유의한 차이가 없는 정확도를 달성하였으며, 모든 호출률에서 교체형보다 높은 평균 정확도를 보였다. 다만 출처가 겹치는[5] 영어 두 데이터셋과 단일 LLM으로 평가하였고, 비용을 호출률로만 측정하였다. 향후에는 다국어 데이터와 여러 LLM, 금액 기준 비용으로 평가를 확장할 계획이다.

참고 문헌

- [1] P. Amaty, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [2] P. Amaty and V. Setty, "Multilingual Fact-Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [3] M. Schlee et al., "LabelFusion: Fusing Large Language Models with Transformer Encoders for Robust Financial News Classification," arXiv:2512.10793, 2025.
- [4] T. Burleigh, "Do Small Language Models Know When They're Wrong? Confidence-Based Cascade Scoring for Educational Assessment," arXiv:2604.19781, 2026.
- [5] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [6] F. Arslan, N. Hassan, C. Li, and M. Tremayne, "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.
- [7] Z. Wang et al., "Signed Rescue Routing: Harm-Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [8] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.