

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈, 김은경*

국립한밭대학교

20221065@edu.hanbat.ac.kr, *ekim@hanbat.ac.kr

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee, Eunkyung Kim*

Hanbat National Univ.

요약

팩트체크 필요성 탐지(check-worthiness detection)는 유입되는 문장 중 사실 확인이 필요한 문장을 선별하는 기술로, 모든 문장에 대형 언어 모델(LLM)을 호출하면 비용과 지연이 크다. 본 논문에서는 라벨로 학습한 저비용 분류기가 불확실하게 판정한 문장에만 LLM을 호출하고, LLM의 판정으로 교체하는 대신 두 모델의 점수를 결합하는 결합형 캐스케이드를 제안한다. CLEF 2024와 ClaimBuster에서 평가한 결과, 제안 방법은 호출률 50%에서 LLM만 전량 호출한 경우와 유의한 차이가 검출되지 않는 정확도(CLEF 0.923, ClaimBuster 0.846)를 보였고, 교체형(50%)보다 적은 30~40%의 호출률에서 전량 호출 수준에 도달하였다. 이때 LLM 비용은 50%, 처리 시간은 44% 줄었다. 또한 선행 연구 NN-PPI를 재현하여, 같은 라벨로 학습한 분류기만으로도 NN-PPI와 같거나 높은 정확도를 얻음을 보인다.

I. 서론

팩트체크 필요성 탐지는 유입되는 모든 문장을 판정해야 하므로, 실제 서비스 운영사는 모든 문장에 LLM을 적용하는 것이 비현실적이라고 보고하였으며[1], 같은 연구진은 인코더가 확신하지 못할 때만 LLM에 넘기는 하이브리드 방식을 향후 과제로 제시하였다[2].

이러한 하이브리드는 일반적으로 캐스케이드[4] 형태로 구현되며, 분류기가 넘긴 문장의 판정을 LLM의 답으로 교체한다. 그러나 LLM의 판정 기준이 데이터셋 라벨과 다를 경우, 교체는 분류기의 옳은 판정까지 틀리게 바꿀 수 있다[7]. 본 논문에서는 저비용 분류기가 불확실한 문장에서만 LLM을 호출하고, 두 모델의 점수를 라벨로 학습한 가중치로 결합하는 결합형 캐스케이드를 제안한다.

II. 본론

2.1 선행 연구

NN-PPI[1]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. LabelFusion[3]은 인코더와 LLM의 출력을 결합하지만 모든 입력에 LLM을 호출하며, 넘긴 입력에서만 두 모델의 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었다[8]. SRR[7]은 옳은 답을 뒤집는 손실까지 예측하여 넘긴 입력을 고르지만 넘긴 입력은 큰 모델의 답으로 교체한다. 반면 본 논문은 넘긴 입력의 판정 방식을 바꾸며, 결합 가중치를 라벨로 학습하여 LLM과 라벨의 판정 기준 차이를 반영한다.

2.2 전체 구조

제안 방법(그림 1)에서는 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 가장 불확실한 문장, 즉 결정값의 절댓값 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만큼 골라 LLM을 호출한다. 호출하지 않은 문장은 분류기의 판정($d(x)>0$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. 결합형 캐스케이드의 전체 구조

2.3 저비용 분류기

문장 x 의 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 라벨이 있는 학습 세트 L (NN-PPI의 보정 세트)을 사용한다. 저비용 분류기(이하 임베딩 SVM)는 첫 단계의 비용을 최소화하도록, NN-PPI가 이웃 검색에 사용하는 문장 임베딩(all-MiniLM-L6-v2)을 입력으로 하는 RBF-SVM이며, 클래스 불균형을 고려한 가중치로 L 에서 학습한다. 결정값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이며, 절댓값이 클수록 확신이 높다. 추론 시간은 CPU에서 문장당 약 6 ms이다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 분류기의 결정값 $d(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

여기서 (a, b, c) 는 L 에서 5점 교차적합으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 식 (1)을 s 에 대해 정리하면 결합형은 s 를 $(-c-a \cdot d)/b$ 와 비교하게 되므로, LLM 점수의 판정 기준이 분류기의 결정값에 따라 달라진다. 반면 비교 대상인 교체형 캐스케이드(이하 교체형)는 같은 문장에 LLM을 호출하되 d 를 사용하지 않고, s 를 L 에서 정한 고정 임계값 t 와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 영어 데이터[5]는 2,405문장을 학습 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 사용하였다. ClaimBuster[6]는 2012년 토론 1,314문장과 2016년 토론 2,745문장을 각각 학습 세트와 테스트로 사용

하였다. NN-PPI는 원 논문과 같이 Gemma 3 4B로 재현하였으며, 원 논문과 같은 분할(CLEF dev-test, ClaimBuster 2016년)에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 0.827, 0.760). LLM은 Claude Sonnet 5를 사용하였고, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다(문장 단위 채점과 AUC 0.991 대 0.990).

3.2 평가 방법

평가 지표는 테스트 정확도이며, 학습 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고한다. 방법 간 차이는 5회 각각의 예측에 McNemar 검정($\alpha=0.05$, 다중 비교 보정 없음)을 적용하여 유의한 횟수를 보고한다. LLM 임계값, 결합 계수, 호출률, NN-PPI의 이웃 수 k 는 모두 학습 세트 안에서만 정하였고(두 데이터셋 모두 $k=10$), 임베딩 SVM은 기본 하이퍼파라미터를 사용하였다. 호출률은 학습 세트의 교차검증 정확도가 두 데이터셋 모두 거의 오르지 않는 50%로 정하였다(50% 이후 증가 CLEF 0.06%p, ClaimBuster 0.11%p, 전량 호출과 0.7%p 이내).

3.3 실험 결과

표 1. 테스트 정확도 (†: 제안 대비 5회 중 3회 이상 $p<0.05$)

방법	호출률	CLEF	ClaimBuster
Gemma 3 4B + NN-PPI [1]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.790
LLM 전량 호출	100%	0.896†	0.835
+ 임계값 조정	100%	0.915	0.830†
+ NN-PPI [1]	100%	0.897†	0.826†
교체형 캐스케이드	50%	0.916	0.835†
결합형 캐스케이드 (제안)	50%	0.923	0.846

표 1에서 LLM을 사용하지 않는 임베딩 SVM은 NN-PPI보다 CLEF에서 5회 중 4회 유의하게 높았고, ClaimBuster에서는 5회 모두 유의한 차이가 없었다.

LLM 점수를 0.5 기준으로 쓰면 정밀도는 CLEF 0.98, ClaimBuster 0.91이나 재현율은 0.61, 0.42에 그쳤다. 라벨로 임계값을 조정하면 재현율은 0.94, 0.86으로 오르나, ClaimBuster 정확도는 오히려 0.5%p 낮아졌다. 이는 LLM의 판정 기준이 라벨과 다를 수 있음을 시사한다.

호출률 50%의 결합형(CLEF 0.923, ClaimBuster 0.846)은 LLM 전량 호출 중 더 나은 설정(CLEF는 임계값 조정, ClaimBuster는 조정 전)과 비교하여 5회 모두 유의한 차이가 검출되지 않았으며($p\geq 0.10$), NN-PPI를 적용한 전량 호출보다는 5회 모두 유의하게 높다($p\leq 0.016$).

결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았으며(그림 2), 그 차이는 CLEF 20~30%, ClaimBuster 20% 이상의 호출률에서 5회 중 3회 이상 유의하였다. 한편 교체형도 호출률 50%에서 LLM 전량 호출 수준에 이르므로(CLEF +0.01%p, ClaimBuster +0.05%p) 호출 절감 자체는 캐스케이드 구조에서 비롯되며, 결합형은 이 수준에 CLEF 30%, ClaimBuster 40%의 호출률로 도달하였다. 호출률을 100%로 늘리면 정확도가 CLEF 0.1%p, ClaimBuster 0.6%p 더 향상되었고, ClaimBuster에서는 이 차이가 5회 모두 유의하였다.

테스트 배치 23개를 다시 호출하여 측정한 1,000문장당 LLM 비용(Claude Sonnet 5 평가)은 전량 호출 \$0.168, 결합형 50% \$0.084, 30% \$0.051이고, 순차 처리 시간은 각각 107초, 60초, 38초였다(임베딩 SVM 포함).

LLM을 Claude Haiku 4.5로 바꾸어도 결합형(50%)은 전량 호출(0.934, 0.849)과 5회 모두 유의한 차이가 검출되지 않았으나(0.929, 0.850), 교체형(0.920, 0.844)은 CLEF에서 5회 중 3회 유의하게 낮았다. 다만 NN-PPI를 적용한 전량 호출(0.930, 0.839)보다 유의하게 높지는 않았다.

두 방법은 같은 문장에 LLM을 호출하므로 차이는 판정 방식에서만 생긴다. 예를 들어 CLEF의 한 공약 문장(라벨: 불필요)은 LLM 점수가 $s=0.35$ 로, 임계값 $t=0.16$ 을 사용하는 교체형은 ‘필요’로 잘못 판정하였으나, 결합형은 분류기의 결정값($d=-0.84$)에 따라 판정 기준이 0.41로 높아져 옳게 판정하였다. CLEF 1회차에서 LLM을 호출한 절반 중 결합형만 옳게 판정한 문장은 36개, 교체형만 옳게 판정한 문장은 24개였다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 떠는 표준편차)

IV. 결론

본 논문에서는 저비용 분류기가 불확실한 문장에서만 LLM을 호출하고 두 모델의 점수를 결합하는 결합형 캐스케이드를 제안하였다. 제안 방법은 호출률 50%에서 LLM 비용을 절반으로, 처리 시간을 44% 줄이면서도 LLM만 전량 호출한 경우와 유의한 차이가 검출되지 않는 정확도를 보였다. 호출 절감은 캐스케이드 구조에서 비롯되며, 결합은 교체보다 적은 호출로 같은 정확도에 도달하였다. 다만 출처가 겹치는[5] 영어 두 데이터셋으로만 평가하였다.

참고 문헌

- [1] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [2] P. Amatya and V. Setty, "Multilingual Fact-Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [3] M. Schlee et al., "LabelFusion: Fusing Large Language Models with Transformer Encoders for Robust Financial News Classification," arXiv:2512.10793, 2025.
- [4] T. Burleigh, "Do Small Language Models Know When They're Wrong? Confidence-Based Cascade Scoring for Educational Assessment," arXiv:2604.19781, 2026.
- [5] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [6] F. Arslan, N. Hassan, C. Li, and M. Tremayne, "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.
- [7] Z. Wang et al., "Signed Rescue Routing: Harm-Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [8] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.