

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈, 김은경*

국립한밭대학교

20221065@edu.hanbat.ac.kr, *ekim@hanbat.ac.kr

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee, Eunkyung Kim*

Hanbat National Univ.

요약

팩트체크 필요성 탐지(check-worthiness detection)는 수많은 문장 중 사실 확인이 필요한 문장을 골라내는 기술이다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 모든 문장에 LLM을 호출하면 비용과 처리 시간이 크게 늘어난다. 본 논문에서는 가벼운 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 확신하지 못하는 문장에만 LLM을 호출하되 분류기의 판정을 LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 두 공개 데이터셋(CLEF 2024, ClaimBuster)에서 평가한 결과, 제안 방법은 LLM 호출을 절반으로 줄이면서도 모든 문장에 LLM을 호출한 경우와 같은 수준의 정확도(CLEF 0.923, ClaimBuster 0.846)를 유지하였다. 정확도는 평균적으로 오히려 0.8~1.1%p 높았고, 통계적으로도 0.6%p 넘게 낮지 않음을 확인하였다. 이를 통해 LLM 비용은 약 50%, 처리 시간은 약 44% 줄일 수 있을 것으로 기대된다.

I. 서론

온라인 허위 정보가 급증하면서 팩트체크의 중요성이 커졌으며, 그 첫 단계는 사실 확인이 필요한 주장을 찾아내는 팩트체크 필요성 탐지이다[3]. 이 단계는 들어오는 모든 문장을 판정해야 하므로 처리할 문장이 매우 많다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 실제 팩트체크 서비스 운영사는 모든 문장에 대형 LLM을 호출하는 것은 운영 규모에서 감당하기 어렵다고 보고하였다[1]. 같은 연구진은 소형 인코더가 확신하지 못하는 문장만 LLM에 넘기는 방식을 향후 과제로 제시하였다[2].

이처럼 가벼운 모델이 먼저 판정하고 확신하지 못하는 입력만 큰 모델에 넘기는 구조를 캐스케이드라 하며, 일반적으로 넘긴 입력의 판정은 큰 모델의 판정으로 교체한다[5]. 그러나 어떤 문장을 사실 확인이 필요하다고 볼지에 대한 LLM의 기준은 데이터셋의 라벨(사람이 붙인 정답)과 다를 수 있으며, 이 경우 교체는 분류기가 이미 맞힌 판정까지 틀리게 바꿀 수 있다[5]. 본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하되, LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 결합 가중치는 라벨이 있는 데이터로 학습하므로, LLM의 기준과 라벨 사이의 차이를 보정한다.

II. 본론

2.1 선행 연구

NN-PPI[1]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. 넘긴 입력에서만 두 모델의 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었고[6], SRR[5]는 옳은 답을 뒤집는 손실까지 예측하여 넘긴 입력을 고르지만 넘긴 입력은 큰 모델의 답으로 교체한다. 본 논문은 결합 가중치를 라벨로 학습해 LLM과 라벨의 기준 차이를 반영한다.

2.2 전체 구조

제안 방법(그림 1)에서는 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 가장 불확실한 문장, 즉 결정값의 절댓값 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만큼 골라

LLM을 호출한다. 호출하지 않은 문장은 분류기의 판정($d(x)>0$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. 결합형 캐스케이드의 전체 구조

2.3 저비용 분류기

문장 x 의 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 라벨이 있는 학습 세트 L (NN-PPI의 보정 세트)을 사용한다. 저비용 분류기(이하 임베딩 SVM)는 문장 임베딩 all-MiniLM-L6-v2를 입력으로 하는 RBF-SVM으로, 이 임베딩은 NN-PPI가 이웃 검색에 사용하는 것과 같다. 클래스 불균형을 고려한 가중치로 L 에서 학습하며, 결정값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이고 절댓값이 클수록 확신이 높다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 분류기의 결정값 $d(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

여기서 (a, b, c) 는 L 에서 5점 교차적합으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 식 (1)을 s 에 대해 정리하면 결합형은 s 를 $(-c-a \cdot d)/b$ 와 비교하게 되므로, LLM 점수의 판정 기준이 분류기의 결정값에 따라 달라진다. 반면 비교 대상인 교체형 캐스케이드(이하 교체형)는 같은 문장에 LLM을 호출하되 d 를 사용하지 않고, s 를 L 에서 정한 고정 임계값 t 와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 영어 데이터[3]는 2,405문장을 학습 세트로, dev-dev-test 공식 test를 합친 1,691문장을 테스트로 사용하였다. ClaimBuster[4]는 2012년 토론 1,314문장

과 2016년 토론 2,745문장을 각각 학습 세트와 테스트로 사용하였다. NN-PPI는 원 논문과 같이 Gemma 3 4B로 재현하였으며, 원 논문과 같은 분할(CLEF dev-test, ClaimBuster 2016년)에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 0.827, 0.760). LLM은 Claude Sonnet 5를 사용하였고, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다.

3.2 평가 방법

평가 지표는 테스트 정확도이며, 학습 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고한다. 방법 간 차이는 5회 각각의 예측에 McNemar 검정($\alpha=0.05$, 다중 비교 보정 없음)을 적용하고, 차이의 95% 신뢰구간은 테스트 문장 부트스트랩(2,000회)으로 구하였다. LLM 임계값, 결합 계수, 호출률, NN-PPI의 이웃 수 k 는 모두 학습 세트 안에서만 정하였고(두 데이터셋 모두 $k=10$), 임베딩 SVM은 기본 하이퍼파라미터를 사용하였다. 호출률은 학습 세트의 교차검증 정확도가 두 데이터셋 모두 거의 오르지 않는 50%로 정하였다(50% 이후 증가 CLEF 0.06%p, ClaimBuster 0.11%p).

3.3 실험 결과

표 1. 테스트 정확도 ($\dagger$: 5회 중 3회 이상 제안보다 유의하게 낮음)

방법	호출률	CLEF	ClaimBuster
Gemma 3 4B + NN-PPI [1]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.790
LLM 전량 호출	100%	0.896 $\dagger$	0.835
+ 임계값 조정	100%	0.915	0.830 $\dagger$
+ NN-PPI [1]	100%	0.897 $\dagger$	0.826 $\dagger$
교체형 캐스케이드	50%	0.916	0.835 $\dagger$
결합형 캐스케이드 (제안)	50%	0.923	0.846

표 1에서 LLM을 사용하지 않는 임베딩 SVM은 NN-PPI보다 CLEF에서 5회 중 4회 유의하게 높았고, ClaimBuster에서는 5회 모두 유의차가 없었다.

LLM 점수를 0.5 기준으로 쓰면 재현율이 CLEF 0.61, ClaimBuster 0.42에 그쳤고(정밀도 0.98, 0.91), 임계값을 조정하면 재현율은 오르나 ClaimBuster 정확도는 0.5%p 낮아졌다. 이는 LLM의 기준이 라벨과 다름을 시사한다.

이하 전량 호출은 LLM 전량 호출의 두 설정(조정 전, 임계값 조정) 중 정확도가 높은 쪽(CLEF는 임계값 조정, ClaimBuster는 조정 전)을 뜻한다. 호출률 50%의 결합형은 전량 호출보다 정확도가 평균 0.8%p, 1.1%p 높았고, 5회 모두 차이의 95% 신뢰구간 하한이 -0.6p 이상이었다. 즉 결합형의 정확도는 전량 호출보다 0.6%p 넘게 낮지 않다. 반면 같은 호출률의 교체형은 ClaimBuster에서 하한이 -2.3p 까지 내려가 이를 보장하지 못했다. 또한 결합형은 NN-PPI를 적용한 전량 호출보다 5회 모두 유의하게 높았다($p \leq 0.016$).

테스트 배치 23개를 다시 호출하여 추정한 1,000문장당 LLM 비용(Claude Sonnet 5 정가)은 전량 호출 \$0.168, 결합형 50% \$0.084였고, 순차 처리 시간은 107초, 60초로 추정되었다(임베딩 SVM 문장당 6 ms 포함).

그림 2와 같이 결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았다. 전량 호출의 평균 정확도에 교체형은 호출률 50%에서 이르지만, 결합형은 CLEF 30%, ClaimBuster 40%에서 이르렀다.

두 방법은 같은 문장에 LLM을 호출하므로 차이는 판정 방식에서만 생긴다. 예를 들어 CLEF의 한 공약 문장(라벨: 불필요)은 LLM 점수가 $s=0.35$ 로, 임계값 $t=0.16$ 을 사용하는 교체형은 ‘필요’로 잘못 판정하였으나, 결합형은 분류기의 결정값($d=-0.84$)에 따라 판정 기준이 0.41로 높아져 옳게 판정하

였다. CLEF 1회차에서 LLM을 호출한 절반 중 결합형만 옳게 판정한 문장은 36개, 교체형만 옳게 판정한 문장은 24개였다.

LLM을 Claude Haiku 4.5로 바꾸어도 결합형(50%)의 정확도는 전량 호출보다 1.6%p 넘게 낮지 않았으나(5회 모두), 교체형은 CLEF에서 하한이 -3.1p 까지 내려갔다. 단, 이때 결합형은 NN-PPI를 적용한 전량 호출(0.930, 0.839)보다 유의하게 높지 않았다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 락은 표준편차)

IV. 결론

본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하고, 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안하였다. 제안 방법은 LLM 호출을 절반으로 줄이면서도 모든 문장에 LLM을 호출한 경우와 같은 수준의 정확도를 유지하였으며, 이에 따라 LLM 비용은 약 50%, 처리 시간은 약 44% 줄일 수 있을 것으로 기대된다. 다만 학습 데이터(2012년 토론)와 시기가 다른 ClaimBuster 테스트(2016년 토론)에서는 분류기의 재현율이 0.59에 그쳐 (CLEF 0.85), 제안 방법도 확인이 필요한 문장을 임계값을 조정한 LLM 전량 호출보다 많이 놓쳤다(재현율 0.73 대 0.86). 이러한 분류기의 노후화는 LLM을 호출한 문장에서 LLM만 ‘필요’로 판정한 비율로 라벨 없이 감지할 수 있었고(학습 데이터 15.9% → 테스트 23.6%, CLEF는 증가 없음), 최근 문장 300개로 다시 학습하면 재현율이 3.7%p 올랐다. 또한 출처가 겹치는[3] 영어 두 데이터셋으로만 평가하였으므로, 향후에는 분류기의 주기적 재학습과 다국어 데이터로 평가를 확장할 계획이다.

참고 문헌

- [1] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [2] P. Amatya and V. Setty, "Multilingual Fact-Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [3] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [4] F. Arslan, N. Hassan, C. Li, and M. Tremayne, "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.
- [5] Z. Wang et al., "Signed Rescue Routing: Harm-Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [6] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.