

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈
(소속 입력 필요)
leejb020313@gmail.com

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee
(Affiliation)

요약

팩트체크 필요성 탐지(check-worthiness detection)는 유입되는 모든 문장에 적용되므로, 모든 문장에 대형 언어 모델(LLM)을 호출하면 비용과 지연이 크다. 본 논문은 소형 LLM 점수를 이웃 문장으로 보정하는 선행 연구 NN-PPI를 CLEF 2024와 ClaimBuster에서 재현하고, 같은 라벨과 문장 임베딩으로 학습한 저비용 분류기만으로도 NN-PPI와 같거나 높은 정확도를 얻음을 보인다. 이어 분류기가 불확실한 문장에만 LLM을 호출하고, 그 판정을 LLM의 답으로 교체하는 대신 두 점수를 결합하는 결합형 캐스케이드를 제안한다. LLM 호출을 절반으로 줄여도 테스트 정확도(CLEF 0.923, ClaimBuster 0.846)는 LLM 단독 전량 호출의 최고 정확도(0.915, 0.835)와 유의한 차이가 없었고, NN-PPI를 적용한 전량 호출(0.897, 0.826)보다는 유의하게 높았다. 결합형은 모든 호출률에서 교체형 캐스케이드보다 평균 정확도가 높아, 라벨에 담긴 판정 기준과 LLM의 일반 지식이 서로 보완적임을 시사한다.

I. 서론

팩트체크 필요성 탐지는 유입되는 모든 문장에 적용되므로, 실제 팩트체크 서비스 운영사는 모든 문장에 LLM을 적용하는 것이 비현실적이라고 보고하였다[1]. 이에 NN-PPI[1]는 소형 LLM의 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장의 잔차로 보정한다. 같은 연구진은 과인튜닝한 소형 인코더도 LLM과 경쟁할 수 있으나 관용적 표현에서는 LLM이 앞선다고 보고하며, 인코더가 확신하지 못할 때만 LLM에 넘기는 하이브리드를 향후 과제로 남겼다[2].

이러한 하이브리드의 일반적 형태인 캐스케이드[4]는 넘긴 입력의 판정을 LLM의 답으로 교체한다. 그러나 LLM의 판정 기준은 데이터셋 라벨과 다를 수 있어, 교체는 분류기의 옳은 판정까지 틀리게 바꿀 수 있다[7]. LabelFusion[3]은 인코더와 LLM의 출력을 결합하지만 모든 입력에 LLM을 호출하며, 넘긴 입력에서만 두 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었다[8]. 본 논문은 [2]의 하이브리드를 팩트체크 필요성 탐지에 구현하되, 결합 가중치를 라벨로 학습하여 LLM과 라벨의 판정 기준 차이까지 반영한다.

본 논문의 기여는 세 가지이다. (1) NN-PPI를 재현하고, 같은 라벨과 임베딩으로 학습한 분류기가 LLM 없이도 NN-PPI와 같거나 높은 정확도를 얻을 보인다. (2) 상용 LLM을 모든 문장에 적용해도 팩트체크가 필요한 문장을 상당수 놓침을 보인다. (3) 분류기가 불확실한 문장에서만 LLM 점수를 결합하는 결합형 캐스케이드를 제안하고, 호출을 절반으로 줄여도 전량 호출과 유의한 차이가 없는 정확도를 얻음을 보인다.

II. 제안 기법

2.1 저비용 분류기

문장 x 에 대해 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 학습에는 NN-PPI와 같은 라벨 있는 보정 세트 L 을 쓴다. 저비용 분류기(이하 임베딩 SVM)는 NN-PPI가 이웃 검색에 쓰는 문장 임베딩(all-MiniLM-L6-v2)을 입력으로 하는 RBF-SVM으로, 클래스 불균형을 고려한 가중치로 L 에서 학습한다. 결정

값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이고, 절댓값이 클수록 분류기가 확신한다는 뜻이다. 추론은 CPU에서 문장당 약 6 ms가 걸린다.

2.2 결합형 캐스케이드

결합형 캐스케이드(이하 결합형)는 그림 1과 같이 동작한다. 분류기가 가장 불확실한 문장, 즉 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만큼 골라 LLM을 호출하고 점수 $s(x) \in [0,1]$ 을 얻는다. 호출한 문장은 식 (1)로 d 와 s 를 결합해 판정하고, 나머지 문장은 분류기의 판정($d(x) > 0$)을 그대로 쓴다.




그림 1. 결합형 캐스케이드의 구조

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

(a, b, c)는 L 에서 5점 교차적합으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 비교 대상인 교체형 캐스케이드(이하 교체형)는 같은 문장에 LLM을 호출하되, d 를 버리고 s 에 L 에서 고른 임계값만 적용한다.

III. 실험 및 결과

3.1 실험 설정

데이터. CLEF 2024 CheckThat! Task 1 영어 데이터[5]는 2,405문장을 보정 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 썼다. ClaimBuster[6]는 2012년 토론 1,314문장을 보정 세트로, 2016년 토론 2,745문장을 테스트로 썼다.

모델. NN-PPI는 원 논문과 같이 Gemma 3 4B로 재현하였다. 원 논문과 같은 분할(CLEF dev-test, ClaimBuster 2016년)에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 0.827,

0.760). 이웃 수 k 는 보정 세트 내부 검증으로 정하였다(두 데이터셋 모두 $k=10$). LLM은 Claude Sonnet 5이며, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다. 문장 단위로 채점한 표본에서 AUC는 0.991 대 0.990으로 묶음 채점과 거의 같았다.

평가. LLM 임계값, 결합 계수, k , 호출률은 모두 보정 세트 안에서만 정하였고, 임베딩 SVM은 기본 하이퍼파라미터를 썼다. 보정 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고하며, 방법 간 차이는 1회차 예측에 McNemar 검정 ($\alpha=0.05$)을 적용해 평가하였다.

3.2 결과

표 1. 테스트 정확도 (5회 평균, †: 제안 방법(호출률 50%)보다 유의하게 낮음, McNemar $p<0.05$)

방법	호출률	CLEF	ClaimBuster
Gemma 3 4B + NN-PPI [1]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.790
LLM 전량 호출	100%	0.896†	0.835
+ 임계값 조정	100%	0.915	0.830†
+ NN-PPI [1]	100%	0.897†	0.826†
교체형 캐스케이드	50%	0.916	0.835†
결합형 캐스케이드 (제안)	50%	0.923	0.846

LLM 없이도 NN-PPI와 같거나 높다. 임베딩 SVM은 CLEF에서 NN-PPI보다 유의하게 높았고($p=0.013$), ClaimBuster에서는 차이가 유의하지 않았다($p=0.79$).

LLM 단독은 팩트체크가 필요한 문장을 놓친다. LLM 점수를 그대로(0.5 기준) 쓰면 정밀도는 CLEF 0.98, ClaimBuster 0.91로 높지만 재현율은 0.61, 0.42에 그쳤다. 라벨로 임계값을 조정하면 재현율이 0.94, 0.86으로 올라, LLM의 판정 기준이 데이터셋 라벨과 다름을 시사한다. 다만 ClaimBuster는 보정 세트가 클래스 균형인 반면 테스트는 팩트체크가 필요한 문장이 27%뿐이어서, 조정 후 정확도가 오히려 0.5%p 낮아졌다.

호출을 절반으로 줄여도 정확도가 유지된다. 호출률 50%는 보정 세트에서 정하였다. 교차적합 정확도가 50% 이후 0.1%p 이하로만 올랐고, 전량 호출과의 차이도 0.7%p 이내였기 때문이다. 이 호출률에서 결합형은 LLM 전량 호출 중 더 나은 설정(CLEF는 임계값 조정, ClaimBuster는 조정 전)과 유의한 차이가 없었고(CLEF $p=0.22$, ClaimBuster $p=0.18$), NN-PPI를 적용한 전량 호출보다는 유의하게 높았다($p<0.001$). 그림 2와 같이 호출률을 100%로 올리면 정확도가 CLEF 0.1%p, ClaimBuster 0.6%p 더 오르며, ClaimBuster에서는 이 차이가 유의하였다($p=0.006$). 또한 테스트 문장을 모아 | d | 순으로 고르는 대신, 보정 세트에서 정한 | d | 임계값으로 문장마다 바로 호출 여부를 정해도 정확도는 0.920, 0.845였다(실제 호출률 38%, 49%).

교체보다 결합이 낫다. 결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았고, ClaimBuster 30~50%와 CLEF 20~30%에서는 차이가 유의하였다($p\leq 0.023$). 두 방식은 같은 문장에 LLM을 호출하므로, 이 차이는 호출한 뒤 판정하는 방식에서 온다. 예를 들어 CLEF의 공약 문장 “I’m going to give them \$5,000 to take with them wherever they want to go, and this will give them affordability.”(라벨: 불필요)은 LLM 점수가 $s=0.35$ 여서, 임계값 0.16을 쓰는 교체형은 ‘필요’로 잘못 판정한다. 결합형은 분류기가 ‘불필요’ 쪽으로 기운 만큼($d=-0.84$) LLM에 더 높은 점수(0.41 이상)를 요구하

므로 옳게 판정한다. CLEF 1회차에서 LLM을 호출한 절반 중 결합형만 옳은 문장은 36개, 교체형만 옳은 문장은 24개였다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 떠는 표준편차)

IV. 결론

라벨로 학습한 저비용 분류기와 LLM은 서로 다른 정보를 가지며, 분류기가 불확실한 문장에서만 LLM을 호출해 두 점수를 결합하면 호출을 절반으로 줄여도 전량 호출과 유의한 차이가 없는 정확도를 얻는다. 또한 결합은 같은 문장을 LLM의 판정으로 교체하는 방식보다 모든 호출률에서 평균 정확도가 높았다. 다만 출처가 겹치는[5] 영어 두 데이터셋과 단일 LLM으로 평가하였고 비용을 호출률로만 측정하였다. 향후 다국어 데이터와 여러 LLM, 금액 기준 비용으로 평가를 확장할 계획이다.

참고 문헌

- [1] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [2] P. Amatya and V. Setty, "Multilingual Fact-Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [3] M. Schlee et al., "LabelFusion: Fusing Large Language Models with Transformer Encoders for Robust Financial News Classification," arXiv:2512.10793, 2025.
- [4] T. Burleigh, "Do Small Language Models Know When They're Wrong? Confidence-Based Cascade Scoring for Educational Assessment," arXiv:2604.19781, 2026.
- [5] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [6] F. Arslan, N. Hassan, C. Li, and M. Tremayne, "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.
- [7] Z. Wang et al., "Signed Rescue Routing: Harm-Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [8] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.