

저비용 분류기와 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈, 노고산, 김은경
국립한밭대학교

20221065@edu.hanbat.ac.kr, {gsnoh, ekim}@hanbat.ac.kr

Cost-Efficient Check-Worthy Claim Detection via Selective Fusion of a Low-Cost Classifier and a Large Language Model

Jeongbin Lee, Gosan Noh, Eunkyung Kim
Hanbat National University

요약

팩트체크 필요성 탐지(check-worthiness detection)는 수많은 문장 중 사실 확인이 필요한 문장을 골라내는 기술이다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 모든 문장에 LLM을 호출하면 비용과 처리 시간이 크게 늘어난다. 본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하되, 분류기의 판정을 LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 두 공개 데이터셋(CLEF 2024, ClaimBuster)에서 평가한 결과, 제안 방법은 LLM 호출을 절반으로 줄이고도 두 종류의 LLM 모두에서 모든 문장에 LLM을 호출한 경우보다 유의하게 낮았던 경우가 100회 반복 실험 중 한 번도 없었으며, LLM의 판정으로 교체하는 방식보다 평균 정확도가 높았다. 특히 판정 기준이 라벨보다 엄격했던 Claude Sonnet 5에서는 전량 호출보다 오히려 1.4~1.8%p 높았다(CLEF 0.924, ClaimBuster 0.853). 이를 통해 LLM 비용은 약 50%, 처리 시간은 약 46% 줄일 수 있을 것으로 기대된다.

I. 서론

온라인 허위 정보가 급증하면서 팩트체크의 중요성이 커졌으며, 그 첫 단계는 사실 확인이 필요한 주장을 찾아내는 팩트체크 필요성 탐지이다[1]. 이 단계는 모든 문장을 판정해야 하므로 처리할 문장이 매우 많다. 대형 언어 모델(LLM)은 이 판정을 잘 수행하지만, 실제 팩트체크 서비스 운영사는 모든 문장에 대형 LLM을 호출하는 것이 운영 규모에서 감당하기 어렵다고 보고하였다[2]. 같은 연구진은 소형 인코더가 확신하지 못하는 문장만 LLM에 넘기는 방식을 향후 과제로 제시하였다[3].

이처럼 가벼운 모델이 먼저 판정하고 확신하지 못하는 입력만 큰 모델에 넘기는 구조를 캐스케이드라 하며, 흔히 넘긴 입력의 판정은 큰 모델의 판정으로 교체한다[4]. 그러나 어떤 문장을 사실 확인이 필요하다고 볼지에 대한 LLM의 기준은 데이터셋의 라벨(사람이 붙인 정답)과 다를 수 있으며, 이 경우 교체는 분류기가 이미 맞힌 판정까지 틀리게 바꿀 수 있다. 본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하되, LLM의 판정으로 교체하지 않고 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안한다. 결합 가중치는 라벨로 학습하므로 LLM의 기준과 라벨의 차이를 보정한다.

II. 본론

2.1 선행 연구

NN-PPI[2]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. SRR[4]은 옳은 답을 뒤집는 손실까지 예측하여 넘긴 입력을 고르지만 넘긴 입력은 큰 모델의 답으로 교체한다. CAUC[5]는 넘긴 입력에서 두 모델의 출력을 결합하지만, 결합 여부를 보정 세트의 검정으로 정할 뿐 결합 방식은 학습하지 않는다. 본 논문은 결합 가중치를 라벨로 학습해 LLM의 기준 차이를 반영한다.

2.2 전체 구조

그림 1은 제안하는 결합형 캐스케이드의 전체 구조이다. 저비용 분류기가 모든 문장을 먼저 판정하고, 분류기가 가

장 불확실한 문장, 즉 결정값의 절댓값 $|d(x)|$ 가 가장 작은 문장부터 전체의 ρ (호출률)만큼 골라(그림 1의 yes 경로) LLM을 호출한다. 호출하지 않은 문장은 분류기의 판정($d(x) > 0$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. 결합형 캐스케이드의 전체 구조

2.3 저비용 분류기

문장 x 의 팩트체크 필요 여부 $y \in \{0,1\}$ 을 판정하며, 라벨이 있는 학습 세트 L (NN-PPI의 보정 세트)을 사용한다. 저비용 분류기(이하 임베딩 SVM)는 NN-PPI가 이웃 검색에 쓰는 문장 임베딩 all-MiniLM-L6-v2를 입력으로 하는 RBF-SVM이다. 클래스 불균형을 고려한 가중치로 L 에서 학습하며, 결정값 $d(x)$ 가 양수이면 팩트체크가 필요하다는 판정이고 절댓값이 클수록 확신이 높다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 분류기의 결정값 $d(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot d(x) + b \cdot s(x) + c) \geq 0.5], \quad (1)$$

여기서 (a, b, c) 는 L 에서 5겹 교차검증으로 얻은 d 와 s 로 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 식 (1)을 s 에 대해 정리하면 결합형은 s 를 $(-c-a \cdot d)/b$ 와 비교하므로, 분류기가 ‘불필요’로 기울수록(즉, d 가 작을수록) LLM에 더 높은 점수를 요구한다. 반면 교체형 캐스케이드(이하 교체형)는 s 를 L 에서 정확도가 가장 높은 임계값 t (표 1의 임계값 조정)와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 데이터[1]는 2,405 문장을 학습 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 사용하였다. 또 다른 데이터셋인 ClaimBuster[6]는 2012년 토론 1,314문장을 학습 세트로, 2016년 토론 2,745문장을 테스트로 사용하였다. NN-PPI는 원 논문[2]과 같이 Gemma 3 4B로 재현하였으며, 원 논문과 같은 분할에서 가중 F1은 CLEF 0.835, ClaimBuster 0.785였다(원 논문 보고값 0.827, 0.760). LLM은 Claude Sonnet 5(표 1, 그림 2)와 비교용 Haiku 4.5를 사용하였고, NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다.

3.2 평가 방법

평가 지표는 테스트 정확도와 가중 F1이며, 학습 세트의 80%를 비복원 추출하여 100회 반복한 평균을 보고한다(LLM 점수와 테스트 세트는 반복 간 동일). 방법 간 차이는 각 반복의 예측에 McNemar 검정($\alpha=0.05$, 다중 비교 보정 없음)을 적용하였다. LLM 임계값, 결합 계수, 호출률, NN-PPI의 이웃 수 k 는 모두 학습 세트 안에서만 정하였고(두 데이터셋 모두 $k=10$), 임베딩 SVM은 기본 하이퍼파라미터를 사용하였다. 호출률은 그 이상 높여도 학습 세트의 교차검증 정확도가 0.3%p 이하로만 오르는 50%로 정하였다.

3.3 실험 결과

표 1. 테스트 정확도(†: 과반 반복에서 제안보다 유의하게 낮음)

방법	호출률	CLEF	ClaimBuster
Gemma+NN-PPI [2]	0%	0.834	0.785
임베딩 SVM	0%	0.859	0.788
LLM 전량 호출	100%	0.897†	0.829†
+ 임계값 조정	100%	0.910†	0.835†
+ NN-PPI [2]	100%	0.905†	0.836†
교체형 캐스케이드	50%	0.913†	0.841†
결합형 캐스케이드 (제안)	50%	0.924	0.853

임베딩 SVM은 NN-PPI보다 CLEF에서 100회 중 87회 유의하게 높았고, ClaimBuster에서는 유의차가 없었다.

0.5를 기준으로 쓰면 Sonnet 5의 재현율은 CLEF 0.62, ClaimBuster 0.40에 그쳐 라벨보다 엄격하였다.

이하 전량 호출은 더 정확한 설정(Sonnet 5는 임계값 조정)을 뜻한다. 호출률 50%의 결합형은 전량 호출보다 정확도가 평균 1.4%p, 1.8%p 높았고 100회 중 81회, 98회 유의하게 높았으며 유의하게 낮은 경우는 없었다. NN-PPI로 LLM 점수를 보정한 전량 호출보다는 93회, 69회 유의하게 높았다. 가중 F1에서도 결합형(0.925, 0.852)이 교체형(0.916, 0.846)과 전량 호출(0.913, 0.842)보다 높았다.

테스트 배치 112개의 사용량으로 추정된 1,000문장당 LLM 비용(정가)은 전량 호출 \$0.396, 결합형 50% \$0.198, 순차 처리 시간은 152초, 82초였다.

그림 2와 같이 결합형은 모든 호출률에서 교체형보다 평균 정확도가 높았다. 호출률 50%에서 교체형은 분류기가 맞힌 판정을 CLEF 63개, ClaimBuster 177개 틀리게 바꿨으나 결합형은 27개, 97개에 그쳤고, 바로잡은 판정 수는 교체형의 88%, 85%였다.

예를 들어 CLEF의 한 공약 문장(라벨: 불필요, $s=0.25$)은 교체형이 $t=0.16$ 기준으로 틀렸으나, 결합형은 $d=-0.85$ 에 따라 기준이 0.41로 높아져 옳게 판정하였다.

Haiku 4.5에서도 결합형(0.930, 0.847)은 교체형

(0.921, 0.843)보다 정확도가 높았다. 결합형은 전량 호출보다 평균 0.4%p, 0.2%p 낮았으나 유의하게 낮은 반복이 없었고, 교체형은 CLEF에서 100회 중 59회 유의하게 낮았다. Haiku는 임계값을 조정하지 않은 전량 호출이 더 정확하여 기준 차이가 작았던 것으로 보이며, LLM의 기준이 라벨과 다를수록 결합의 이득이 커질 것으로 기대된다.

한편 학습 시기와 다른 ClaimBuster 테스트에서는 분류기의 재현율이 0.59에 그쳐(CLEF 0.84), 결합형도 확인이 필요한 문장을 임계값을 조정한 전량 호출보다 많이 놓쳤고(재현율 0.70 대 0.88), ‘필요’ 클래스의 F1도 0.716로 전량 호출(0.739)보다 낮았다. 호출한 문장 중 LLM만 ‘필요’로 판정한 비율이 늘어나(학습 18.5% → 테스트 24.8%) 라벨 없이 성능 저하의 징후로 쓸 수 있어 보인다.




그림 2. 호출률에 따른 테스트 정확도 (100회 평균, 띠는 표준편차)

IV. 결론

본 논문에서는 저비용 분류기가 확신하지 못하는 문장에만 LLM을 호출하고, 두 모델의 점수를 결합하여 최종 판정하는 결합형 캐스케이드를 제안하였다. 제안 방법은 LLM 호출을 절반으로 줄이면서도 두 종류의 LLM 모두에서 전량 호출보다 유의하게 낮지 않았고 교체 방식보다 정확하였으며, 기준이 라벨과 크게 다른 Sonnet 5에서는 전량 호출보다 높았다. 이에 따라 LLM 비용은 약 50%, 처리 시간은 약 46% 줄일 수 있을 것으로 기대된다. 다만 학습 시기와 다른 ClaimBuster 테스트에서는 분류기의 재현율이 낮았으며, LLM만 ‘필요’로 판정하는 비율이 그 징후일 수 있다. 또한 CLEF 영어 데이터가 ClaimBuster에서 구축된[1] 두 영어 데이터셋으로만 평가하였으므로, 향후 분류기의 주기적 재학습을 검증하고 다국어로 평가를 확장할 계획이다.

참고 문헌

- [1] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276-286, 2024.
- [2] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [3] P. Amatya and V. Setty, "Multilingual Fact-Checking at Scale: Fine-Tuned Compact Models vs LLMs," arXiv:2606.08605, 2026.
- [4] Z. Wang et al., "Signed Rescue Routing: Harm-Aware Cascades for Efficient LLM Inference," arXiv:2609.07786, 2026.
- [5] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.
- [6] F. Arslan et al., "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821-829, 2020.