

제로샷 결정 모델과 대형 언어 모델의 선택적 결합을 통한 팩트체크 필요성 탐지

이정빈, 김은경*

국립한밭대학교

leejb020313@gmail.com, *(교신저자 이메일)

Check-Worthy Claim Detection by Selectively Fusing a Zero-Shot Decision Model and a Large Language Model

Lee Jeongbin, Kim Eunkyung*

Hanbat National Univ.

요약

팩트체크 필요성 탐지(check-worthiness detection)는 유입되는 문장 중 사실 확인이 필요한 문장을 선별하는 기술로, 모든 문장에 대형 언어 모델(LLM)을 호출하면 비용과 지연이 크다. 본 논문에서는 텍스트 대신 라벨 확률을 반환하는 결정 전용 모델 JEV를 1 단계로 두고, JEV가 불확실하게 판정한 문장에만 LLM을 호출하여 두 모델의 점수를 결합하는 캐스케이드를 제안한다. CLEF 2024와 ClaimBuster에서 평가한 결과, JEV는 라벨로 학습한 임베딩 분류기보다 정확도가 4.2%p, 6.0%p 높았다. 학습 세트에서 정한 LLM 호출률은 CLEF 30%, ClaimBuster 0%였으며, 이때 정확도(0.924, 0.850)는 CLEF에서 LLM 전량 호출과 유의한 차이가 없었고 ClaimBuster에서는 유의하게 높았다. 또한 두 점수를 결합하는 방식은 LLM을 호출하는 모든 호출률에서 LLM의 판정으로 교체하는 방식보다 평균 정확도가 높았다.

I. 서론

팩트체크 필요성 탐지는 유입되는 모든 문장을 대상으로 사실 확인이 필요한지를 판정하므로 처리할 문장의 수가 많다. 실제 팩트체크 서비스 운영사는 모든 문장에 LLM을 적용하는 것이 비현실적이라고 보고하였으며[1], 이에 저비용 모델이 먼저 판정하고 불확실한 문장만 LLM에 넘기는 캐스케이드가 대안이 된다. 최근 공개된 JEV는 텍스트를 생성하지 않고 라벨마다 확률을 반환하는 결정 전용 모델로, 생성형 LLM보다 훨씬 저렴하다(1,000건당 0.044달러)[2].

JEV를 1단계로 한 캐스케이드는 평가(judging) 과제에서 연구되었으나, JEV가 확실할 때는 그 판정을 받아들이고 나머지는 LLM의 판정으로 교체하는 방식이었다[2]. 또한 JEV와 LLM은 같은 곳에서 틀리는 경향이 있어, 이러한 캐스케이드는 비용만 줄일 뿐 정확도는 거의 높이지 못한다고 보고되었다[3]. 두 모델의 출력을 결합하는 방식은 향후 과제로 남아 있다[2]. 본 논문에서는 JEV를 팩트체크 필요성 탐지의 1 단계로 사용하고, JEV가 불확실한 문장에서만 LLM을 호출하여 두 점수를 라벨로 학습한 가중치로 결합하는 캐스케이드를 제안한다.

II. 본론

2.1 선행 연구

NN-PPI[1]는 소형 LLM이 출력한 점수를, 라벨이 있는 보정 세트에서 의미적으로 가까운 이웃 문장들의 잔차로 보정한다. 넘긴 입력에서만 두 모델의 출력을 결합하는 캐스케이드는 일반 분류 과제에서 제안되었다[4]. 반면 본 논문에서는 학습하지 않은 결정 전용 모델을 1단계로 두고, 그 확률과 LLM 점수의 결합 가중치를 라벨로 학습한다.

2.2 전체 구조

그림 1은 제안 방법의 전체 구조를 나타낸다. JEV가 모든 문장에 대해 팩트체크가 필요할 확률 $p(x)$ 를 출력하면, 학습 세트에서 정한 임계값 θ 에 가장 가까운 문장, 즉 $|\logit p(x) - \logit \theta|$ 가 가장 작은 문장부터 전체의 p (호출률)만큼 골

라 LLM을 호출한다. 호출하지 않은 문장은 JEV의 판정 ($p(x) \geq \theta$)을 그대로 사용하고, 호출한 문장은 2.4절의 결합 판정으로 최종 판정한다.




그림 1. JEV 기반 결합형 캐스케이드의 전체 구조

2.3 JEV 판정

JEV에는 LLM과 같은 NN-PPI의 판정 기준을 구조화된 지시어로 전달하고, 문장마다 판정 기준에 따라 팩트체크가 필요한 주장인지를 묻는 이진 질문으로 확률 $p(x)$ 를 얻었다. 질문 문구는 두 후보 중 학습 세트 200문장에서 AUC가 높은 쪽으로 정하였다. JEV는 추가 학습 없이 사용하며, 라벨은 임계값 θ 를 정하는 데만 쓴다.

2.4 결합 판정

호출한 문장에 대해 LLM이 출력한 점수 $s(x) \in [0,1]$ 와 JEV의 로짓 $\ell(x) = \logit p(x)$ 를 다음과 같이 결합한다.

$$\hat{y}(x) = \mathbb{I}[\sigma(a \cdot \ell(x) + b \cdot s(x) + c) \geq 0.5] \quad (1)$$

여기서 (a, b, c) 는 학습 세트 L에서 학습한 로지스틱 회귀 계수, σ 는 시그모이드 함수, $\mathbb{I}[\cdot]$ 는 조건이 참이면 1인 지시함수이다. 비교 대상인 교체형 캐스케이드(이하 교체형)는 같은 문장에 LLM을 호출하되 ℓ 을 사용하지 않고, s 를 L에서 정한 고정 임계값 t 와 비교한다.

III. 실험

3.1 실험 환경

CLEF 2024 CheckThat! Task 1 영어 데이터[5]는 2,405문장을 학습 세트로, dev·dev-test·공식 test를 합친 1,691문장을 테스트로 사용하였다. ClaimBuster[6]는 2012년 토론 1,314문장과 2016년 토론 2,745문장을 각각 학습 세트와 테스트로 사용하였다. JEV는 TypeSafe API로, LLM은 Claude Sonnet 5로 채

접하였으며, LLM은 NN-PPI의 판정 기준 프롬프트로 40문장씩 묶어 채점하였다. 비교를 위해 JEV 대신 문장 임베딩(all-MiniLM-L6-v2) 기반 RBF-SVM(이하 임베딩 SVM)을 1단계로 쓰는 결합형과, LLM 전량 호출에 NN-PPI를 적용한 설정도 평가하였다.

3.2 평가 방법

평가 지표는 테스트 정확도이며, 학습 세트의 80%를 비복원 추출하여 5회 반복한 평균을 보고한다. 방법 간 차이는 5회 각각의 예측에 McNemar 검정($\alpha=0.05$)을 적용하여 평가하였다. 임계값, 결합 계수, 호출률은 모두 학습 세트 안에서만 정하였다. 호출률은 캐스케이드마다 학습 세트의 교차검증 정확도가 그 이후 0.1%p 이하로만 오르는 가장 작은 값으로 정하였다.

3.3 실험 결과

표 1. 테스트 정확도 (†: 5회 중 3회 이상 제안보다 유의하게 낮음)

방법	호출률	CLEF	ClaimBuster
임베딩 SVM	0%	0.859†	0.790†
JEV (임계값 조정)	0%	0.901†	0.850
LLM 전량 호출	100%	0.896†	0.835†
+ 임계값 조정	100%	0.915	0.830†
+ NN-PPI [1]	100%	0.897†	0.826†
SVM→LLM 결합형	50%/60%	0.923	0.849
JEV→LLM 교체형	30%/0%	0.908†	0.850
JEV→LLM 결합형(제안)	30%/0%	0.924	0.850

표 1은 각 방법의 테스트 정확도를 비교한 결과이다. JEV는 라벨로 학습하지 않았음에도 임베딩 SVM보다 CLEF에서 4.2%p, ClaimBuster에서 6.0%p 높았다(5회 모두 유의). JEV 단독의 정확도는 LLM 전량 호출의 더 나은 설정과 비교하여 CLEF에서는 5회 중 4회 유의하게 낮았으나, ClaimBuster에서는 5회 모두 유의하게 높았다.

제안한 결합형의 호출률은 학습 세트에서 CLEF 30%, ClaimBuster 0%로 정해졌다. CLEF에서는 30% 호출로 0.924를 달성하여 LLM 전량 호출(0.915)과 5회 모두 유의한 차이가 없었고, 임베딩 SVM을 1단계로 쓴 결합형이 50% 호출로 얻은 정확도(0.923)와도 차이가 없었다. ClaimBuster에서는 JEV 단독이 이미 LLM 전량 호출보다 높아 학습 세트가 LLM 호출을 선택하지 않았으며, LLM 호출 없이도 임베딩 SVM 결합형(60% 호출, 0.849)과 차이가 없었다. 다만 테스트에서는 20% 호출 시 0.861까지 올랐으나, 학습 세트에서는 이득이 나타나지 않아 선택되지 않았다. 두 데이터셋 모두 NN-PPI를 적용한 전량 호출보다는 5회 모두 유의하게 높았다.

그림 2는 호출률에 따른 테스트 정확도를 나타낸다. JEV를 1단계로 쓰면 곡선이 임베딩 SVM보다 높은 곳에서 시작하므로, 같은 정확도에 훨씬 적은 호출로 도달한다. 결합형은 LLM을 호출하는 모든 호출률에서 교체형보다 평균 정확도가 높았고, 그 차이는 CLEF 20~60%, ClaimBuster 30% 이상의 호출률에서 5회 중 3회 이상 유의하였다. 특히 ClaimBuster에서 교체형은 호출을 늘릴수록 정확도가 0.857에서 0.830까지 떨어졌는데, 이는 교체가 JEV의 옳은 판정을 LLM의 틀린 판정으로 바꾸기 때문으로 해석된다.




그림 2. 호출률에 따른 테스트 정확도 (5회 평균, 떠는 표준편차)

IV. 결론

본 논문에서는 결정 전용 모델 JEV를 1단계로 두고 불확실한 문장에서만 LLM을 호출해 두 점수를 결합하는 캐스케이드를 제안하였다. JEV는 라벨로 학습한 분류기보다 정확하여, LLM 호출률을 CLEF에서 30%, ClaimBuster에서 0%로 낮추면서도 LLM 전량 호출과 같거나 높은 정확도를 얻었다. 결합은 교체보다 정확도가 높았으나, 두 모델이 같은 곳에서 틀린다는 보고[3]와 같이 CLEF에서 LLM 전량 호출 대비 정확도 이득은 유의하지 않았다. 다만 JEV는 상용 서비스이고, 출처가 겹치는[5] 영어 두 데이터셋과 단일 LLM으로 평가하였다. 향후 다국어 데이터와 여러 결정 모델·LLM으로 평가를 확장할 계획이다.

참고문헌

- [1] P. Amatya, Venkatesh V, and V. Setty, "Calibrating Small Language Models for Claim Check-Worthiness Detection," arXiv:2608.30731, 2026.
- [2] Y. Li, Y. Miao, R. Krishnan, and R. Padman, "JEV-as-a-Judge: Accept When Confident, Escalate When Unsure," arXiv:2609.26550, 2026.
- [3] D. Rao and C. Callison-Burch, "JEV vs. LLMs as Rubric Judges: Cheaper, Faster, and Wrong in the Same Places," arXiv:2609.29769, 2026.
- [4] Y. Zhang et al., "Calibration-Aware Uncertainty Cascades for Efficient Heterogeneous Model Collaboration," arXiv:2609.11446, 2026.
- [5] M. Hasanain et al., "Overview of the CLEF-2024 CheckThat! Lab Task 1 on Check-Worthiness Estimation of Multigenre Content," CEUR-WS vol. 3740, pp. 276–286, 2024.
- [6] F. Arslan, N. Hassan, C. Li, and M. Tremayne, "A Benchmark Dataset of Check-Worthy Factual Claims," in Proc. ICWSM, vol. 14, pp. 821–829, 2020.